

```
!pip install --quiet transformers[torch] sentencepiece datasets evaluate
```

		84.1/84.1	kB	2.3	MB/s	eta	0:00:00
		363.4/363.4	MB	1.4	MB/s	eta	0:00:00
		13.8/13.8	MB	63.1	MB/s	eta	0:00:00
		24.6/24.6	MB	51.5	MB/s	eta	0:00:00
		883.7/883.7	kB	31.2	MB/s	eta	0:00:00
		664.8/664.8	MB	2.8	MB/s	eta	0:00:00
		211.5/211.5	MB	5.3	MB/s	eta	0:00:00
		56.3/56.3	MB	12.5	MB/s	eta	0:00:00
		127.9/127.9	MB	7.2	MB/s	eta	0:00:00
		207.5/207.5	MB	5.9	MB/s	eta	0:00:00
		21.1/21.1	MB	82.9	MB/s	eta	0:00:00

```
import pandas as pd
from transformers import pipeline
from collections import Counter
import matplotlib.pyplot as plt
```

```
from google.colab import files
files.upload()
```

Escolher Ficheiros

kaggle.json

- kaggle.json**(application/json) - 71 bytes, last modified: 18/05/2025 - 100% done

Saving kaggle.json to kaggle.json

```
!mkdir -p ~/.kaggle
!cp kaggle.json ~/.kaggle/
!chmod 600 ~/.kaggle/kaggle.json
```

```
!kaggle datasets download -d marlesson/news-of-the-site-folhauol
```

Dataset URL: <https://www.kaggle.com/datasets/marlesson/news-of-the-site-folhauol>

License(s): CC0-1.0

Downloading news-of-the-site-folhauol.zip to /content

53% 100M/187M [00:00<00:00, 1.05GB/s]

100% 187M/187M [00:00<00:00, 608MB/s]

```
import pandas as pd
from tqdm.auto import tqdm
tqdm.pandas()
```

```
df = pd.read_csv("news-of-the-site-folhauol.zip")
```

```
import zipfile
```

```
with zipfile.ZipFile("news-of-the-site-folhauol.zip", "r") as zip_ref:
    zip_ref.extractall("folha_dataset")
```

```
import pandas as pd
```

```
df = pd.read_csv("folha_dataset/articles.csv", parse_dates=["date"], dayfirst=True)
df.head()
```

	title	text	date	category	subcategory	link	
0	Lula diz que está 'lascado', mas que ainda tem...	Com a possibilidade de uma condenação impedir ...	2017-09-10	poder	NaN	http://www1.folha.uol.com.br/poder/2017/10/192...	
1	'Decidi ser escrava das mulheres que sofrem', ...	Para Oumou Sangaré, cantora e ativista malines...	2017-09-10	ilustrada	NaN	http://www1.folha.uol.com.br/ilustrada/2017/10...	
2	Três reportagens da Folha ganham Prêmio Petrob...	Três reportagens da Folha foram vencedoras do ...	2017-09-10	poder	NaN	http://www1.folha.uol.com.br/poder/2017/10/192...	

Gerar

create a dataframe with 2 columns and 10 rows

Fechar

```
df['date'] = pd.to_datetime(df['date'], errors='coerce')


# Filtro por seção 'mercado' e data entre jan-mar 2015 primeiro trimestre
filtro = (df['category'].str.lower() == 'mercado') & \
    (df['date'].between('2015-01-01', '2015-03-31'))

mercado_df = df.loc[filtro].dropna(subset=['text'])
```

mercado\_df

	title	text	date	category	subcategory	link
99055	Prioridade ao pós-pago reduz número de linhas ...	O mercado de telefonia celular perdeu 2,09 mil...	2015-03-12	mercado	NaN	http://www1.folha.uol.com.br/mercado/2015/12/1...
99063	Dilma sanciona meta fiscal e governo liberará ...	A presidente Dilma Rousseff sancionou a altera...	2015-03-12	mercado	NaN	http://www1.folha.uol.com.br/mercado/2015/12/1...
99064	Reportagem da Folha sobre investidor mais jove...	A reportagem da Folha "Príncipe da Bolsa", de ...	2015-03-12	mercado	NaN	http://www1.folha.uol.com.br/mercado/2015/12/1...
99074	Impeachment pode prejudicar ajuste fiscal no B...	A abertura do processo de impeachment da presi...	2015-03-12	mercado	NaN	http://www1.folha.uol.com.br/mercado/2015/12/1...
99076	Petrobras anuncia 2º reajuste no preço do gás ...	A Petrobras comunicou ao mercado novo reajuste...	2015-03-12	mercado	NaN	http://www1.folha.uol.com.br/mercado/2015/12/1...
...	...	...	...	...	...	...
167000	Em Miami, brasileiros gastam mais com compras ...	Chamam a atenção no caso do Brasil os gastos e...	2015-01-01	mercado	NaN	http://www1.folha.uol.com.br/mercado/2015/01/1...
167004	25% dos municípios brasileiros fecharam vagas ...	Cerca de um quarto dos municípios brasileiros ...	2015-01-01	mercado	NaN	http://www1.folha.uol.com.br/mercado/2015/01/1...

```
ner_pipe = pipeline(
    "ner",
    model="monilouise/ner_news_portuguese",
    tokenizer="monilouise/ner_news_portuguese",
    trust_remote_code=True,
    revision="main",
    aggregation_strategy="simple",
    model_kwargs={"use_safetensors": True}
)
```

 /usr/local/lib/python3.11/dist-packages/huggingface\_hub/utils/\_auth.py:94: UserWarning:

The secret `HF\_TOKEN` does not exist in your Colab secrets.  
To authenticate with the Hugging Face Hub, create a token in your settings tab (<https://huggingface.co/settings/tokens>), set it as secret in your  
You will be able to reuse this secret in all of your notebooks.  
Please note that authentication is recommended but still optional to access public models or datasets.

warnings.warn(

config.json: 1.21k/? [00:00<00:00, 70.3kB/s]

model.safetensors: 100% 436M/436M [00:05<00:00, 71.5MB/s]

Some weights of the model checkpoint at monilouise/ner\_news\_portuguese were not used when initializing BertForTokenClassification: ['bert.pooler.d

- This IS expected if you are initializing BertForTokenClassification from the checkpoint of a model trained on another task or with another archi


- This IS NOT expected if you are initializing BertForTokenClassification from the checkpoint of a model that you expect to be exactly identical (

tokenizer\_config.json: 100% 529/529 [00:00<00:00, 38.6kB/s]

vocab.txt: 210k/? [00:00<00:00, 5.54MB/s]

special\_tokens\_map.json: 100% 112/112 [00:00<00:00, 6.55kB/s]

Device set to use cpu



```
import re

def limpar(ent):
    """Remove tokens quebrados ou irrelevantes."""
    ent = ent.strip()
    if len(ent) <= 2 or re.match(r'^#+', ent):
        return None
    if re.fullmatch(r'[A-Za-z]{1,2}', ent):
        return None
    return ent

from tqdm import tqdm

orgs = []


for texto in tqdm(mercado_df['text'].dropna()):
    if isinstance(texto, str) and texto.strip():
        ents = ner_pipe(texto)
        for ent in ents:
            if ent['entity_group'] == 'ORG':
                nome = limpar(ent['word'])
                if nome:
                    orgs.append(nome)
```

100%|██████████| 2111/2111 [1:04:01<00:00, 1.82s/it]

```
from collections import Counter
import matplotlib.pyplot as plt
```

```
org_freq = Counter(orgs).most_common(30)
if org_freq:
    orgs_list, counts = zip(*org_freq)

    plt.figure(figsize=(10, max(4, len(orgs_list) * 0.4)))
    plt.barh(orgs_list[::-1], counts[::-1])
    plt.title("Ranking com as 30 Organizações mencionadas no periodo do Primeiro trimestre 2015 na categoris Mercado. ")
    plt.xlabel("Frequência em que foi mostrada")
    plt.tight_layout()
    plt.show()
else:
    print(" Nenhuma organização válida encontrada.")
```



Não foi possível ligar ao serviço reCAPTCHA. Verifique a sua ligação à Internet e atualize para obter um desafio reCAPTCHA.